중앙대학교

TabSurv: Adapting Modern Tabular Neural Networks to Survival Analysis

서정호

응용통계학과
(중앙대학교)

2026년 05월 29일

목차

1. 생존분석
2. 문제 정의
3. TabSurv
4. SurvHL
5. 실험 및 결론

생존분석(Survival Analysis)

- 사건 발생 시간 데이터에 대한 연구
- 사건이 언제 발생하는가를 다루는 방법
- 현실에는 모든 사건의 결과를 끝까지 관측하지 못하기에 불완전한 데이터를 다룸
- 회귀분석에서 제한적인 중도절단 데이터도 포함 가능
- 사건 발생 시점의 불확실성에 대한 정량적인 정보 제공
  - 언제 일어날 가능성이 높은지
  - 시간이 지나면서 위험이 어떻게 변하는지
  - 특정 요인이 위험을 얼마나 증가시키는지

중도절단(Censoring)

$$t = \min(T, C) \tag{1}$$

- t: 사건에 대해 관측한 시점
- T: 사건이 실제로 발생한 시점
- C: 관측 종료 시점
- 실제 사건이 발생할 때까지 항상 끝까지 관측은 불가

생존분석 데이터

$$(x, \delta, t) \tag{2}$$

$$\delta = \begin{cases} 1, & \text{사건 발생 관측} \\ 0, & \text{중도절단} \end{cases} \tag{3}$$

- x: 대상 특징
- δ: 사건 발생 여부
- t: 관측한 시점

순간위험

$$h(t) = \lim_{\Delta t \to 0} \frac{P(t \leq T < t + \Delta t | T \geq t)}{\Delta t} \tag{4}$$

- $P(t \leq T < t + \Delta t | T \geq t)$: 시점 t까지 사건이 발생하지 않은 사람이 아주 짧은 Δt 내에 사건을 겪을 확률
- Δt: 시간의 변화량
- 사건 발생 확률을 시간의 변화량으로 나누어 시간 단위당 위험 계산.
- Δt의 값을 아주 작게 하여 특정 시점에서의 순간적인 사건 위험 계산.

비례위험모형

$$h\left(t|x\right) = h_0\left(t\right) \times g\left(x\right) \tag{5}$$

- $h(t|x)$: x라는 설명변수가 있을 때 시점 t에서의 순간위험.
- 시간에 따라 변하는 기본 위험과 설명변수의 효과를 분리하여 모델링.
- $h_0(t)$: 설명변수의 효과를 제외했을 때 시간 t에 의해서만 결정되는 기본위험.
- $g(x)$: 설명변수 x가 기본위험에 미치는 상대적 효과.
- 만약 $g(x) = 0.5$라면 $h(t|x) = 0.5h_0(t)$로 위험이 기존의 50% 수준으로 감소.

Cox 비례위험모형

$$h\left(t|x\right) = h_0\left(t\right) g\left(x\right) \tag{6}$$

$$g(x) = \exp(\beta x) \tag{7}$$

$$h\left(t|x\right) = h_0\left(t\right) \exp(\beta x) \tag{8}$$

- 위험이 음수배가 되는 것은 불가능하기에 항상 양수($g(x) > 0$)로 설정해야 함.
- $\exp(a) > 0 \ \forall a \ \in \mathbb{R}$이기에 위험이 항상 양수가 되도록 보장.

위험비(Hazard Ratio, HR)

$$\mathrm{HR} = \frac{h\left(t|x_1\right)}{h\left(t|x_2\right)} \tag{9}$$

- 생존분석에서는 어떤 요인이 사건 위험에 미치는 영향 분석.
- 위험 $h(t)$: 시간에 따라 변하므로 직접적인 비교와 해석 어려움.
- 위험비 HR: 기준 집단 대비 특정 집단의 상대적인 위험 비율.
- 비례위험 가정: 두 집단의 위험비가 시간과 무관하게 일정하다고 가정.
- $\mathrm{HR} > 1$: 사건 위험 증가, $\mathrm{HR} < 1$: 사건 위험 감소, $\mathrm{HR} = 1$: 집단 간 위험 차이 없음.

위험비 유도(이진 범주형)

$$x = \begin{cases} 0, \text{ 대조군} \\ 1, \text{ 치료군} \end{cases} \tag{10}$$

$$\mathrm{HR} = \frac{h\left(t|x=1\right)}{h\left(t|x=0\right)} \tag{11}$$

$$h\left(t|x=0\right) = h_0\left(t\right)\exp\left(\beta \cdot 0\right) = h_0\left(t\right)\exp\left(0\right) = h_0\left(t\right) \tag{12}$$

$$h\left(t|x=1\right) = h_0\left(t\right)\exp\left(\beta \cdot 1\right) = h_0\left(t\right)\exp\left(\beta\right) \tag{13}$$

$$\mathrm{HR} = \frac{h\left(t|x=1\right)}{h\left(t|x=0\right)} = \frac{h_0\left(t\right)\exp\left(\beta\right)}{h_0\left(t\right)} = \exp\left(\beta\right) \tag{14}$$

위험비 유도(연속형)

$$\mathrm{HR} = \frac{h\left(t|x_1\right)}{h\left(t|x_2\right)} \tag{15}$$

$$h\left(t|x_1\right) = h_0\left(t\right)\exp\left(\beta x_1\right),\ \ h\left(t|x_2\right) = h_0\left(t\right)\exp\left(\beta x_2\right) \tag{16}$$

$$\mathrm{HR} = \frac{h\left(t|x_1\right)}{h\left(t|x_2\right)} = \frac{h_0\left(t\right)\exp\left(\beta x_1\right)}{h_0\left(t\right)\exp(\beta x_2)} = \frac{\exp\left(\beta x_1\right)}{\exp(\beta x_2)} \tag{17}$$

$$\because \frac{\exp(a)}{\exp(b)} = \frac{e^a}{e^b} = e^{a-b} = \exp(a-b) \tag{18}$$

$$\frac{\exp\left(\beta x_1\right)}{\exp(\beta x_2)} = \exp(\beta x_1 - \beta x_2) = \exp(\beta(x_1 - x_2)) \tag{19}$$

Cox 비례위험모형 해석 예시

$$h(t|x) = h_0(t)\exp(\beta x) \tag{20}$$

$$\mathrm{HR} = \exp(\beta) \tag{21}$$

- 흡연 여부(x)에 대한 추정된 계수 $\beta = 0.69$
- 위험비: $\mathrm{HR} = \exp(0.69) \approx 2$
- 흡연자의 사건 발생 위험은 비흡연자 대비 약 2배
- Cox 모형은 설명변수가 사건 발생 위험에 미치는 영향을 정량적으로 해석 가능

생존함수(Survival Function)

$$S(t|x) = P(T > t|x) \tag{22}$$

- 단순히 상대적 위험 비교뿐 아니라 시간에 따라 변화하는 발생 확률도 확인 필요
- $S(t|x)$: 특성 x를 가진 대상이 시점 t까지 사건을 겪지 않을 확률
- 예: $S(5|x) = 0.8$: 특성 x를 가진 대상이 5년까지 사건이 일어나지 않을 확률 80%

누적위험함수

$$H(t) = \int_0^t h(u)\,du \tag{23}$$

- $H(t)$: 누적위험함수
- 시점 0부터 t까지의 순간위험을 누적하는 함수
- 시간이 지날수록 기본 사건 발생 위험이 얼마나 축적되었는지를 나타냄
- 위험이 지속적으로 크다면 $H(t)$ 빠르게 증가
- 누적위험이 증가할수록 사건 발생 확률 증가

Cox PH에서의 생존함수

$$S(t|x) = \exp\left[-\int_0^t h(u|x)\,du\right] = \exp\left[-\exp(\beta x)\int_0^t h_0(u)\,du\right] \tag{24}$$

$$H_0(t) = \int_0^t h_0(u)\,du \tag{25}$$

$$S(t|x) = \exp[-\exp(\beta x)H_0(t)] \tag{26}$$

- 누적위험함수 $H(t)$를 통해 구한 누적위험이 커질수록 생존확률은 감소.
- $-H(t)$로 생존함수에서 생존확률이 시간에 따라 감소하는 형태 표현 가능.
- $H(t) \geq 0$이므로 $-H(t) \leq 0$, 따라서 $0 < \exp(-H(t)) \leq 1$

Cox PH의 한계

- 비례위험 가정 필요
- 선형 형태의 상대위험 모델
- 복잡한 비선형 관계 학습 제한
- 생존함수보다 상대위험의 순서를 잘 구분하도록 적합

생존분석 모델

- 기존에는 전통적인 생존분석 방법들이 높은 성능을 보였음.
- Kaplan-Meier 추정량, Cox 비례위험 모형, Random Survival Forest 등.
- 최근 고차원, 비선형 데이터를 다루는 것을 목표로 하는 딥러닝 모델 등장.
- DeepSurv, DeepHit, SurvTRACE 등.
- Beran 추정량과 같은 비모수적 방법도 시도되고 있음.

표 형식 딥러닝 모델

- 표 형식 딥러닝 모델은 TabR, TabM, RealMLP 등과 같이 활발히 발전 됨.
- 하지만 유사한 데이터를 쓰는 생존분석 모델은 동일한 수준으로 발전하지 못함.
- 딥러닝 모델은 입력 →백본 →출력의 형태로 각 부위를 교체해 실험할 수 있음.
- 하지만 생존분석 모델은 구조가 생존분석에 강하게 엮여있어 유연하지 않음.
- DeepSurv: Cox PH 모델 구조를 그대로 사용해 비례 위험가정 필요.
- DeepHit: 비례위험 가정은 필요 없으나 이산형 시간축 구간을 기반으로 분석.
- SurvTRACE: 데이터 규모가 적은 생존분석에 적합하지 않은 트랜스포머 사용.

시간 구간화

$$p_i(x) = P(T \in [\tau_i, \tau_{i+1})|x) \tag{27}$$

$$0 < \tau_1 < \cdots < \tau_m < \tau_{m+1} = +\infty \tag{28}$$

- 연속적인 위험함수를 모델링하지 않음.
- 시간을 여러 구간을 나누어 구간 내 사건 발생 확률 예측.
- τ: 시간 기준점($\tau_1 = 1,\ \tau_2 = 3,\ \tau_3 = 5$라면 1년, 3년, 5년을 기준으로 시간 나눔)
- T: 실제 사건 발생 시간
- $p_i(x)$: 특성 x가 있는 대상이 i번째 구간에서 사건을 겪을 확률

시간 구간화 예시

$$\tau_1 = 0,\ \tau_2 = 1,\ \tau_3 = 3,\ \tau_4 = 5,\ \tau_5 = \infty \tag{29}$$

$$p_1(x) = P(T \in [0, 1)|x) \tag{30}$$

$$p_2(x) = P(T \in [1, 3)|x) \tag{31}$$

$$p_3(x) = P(T \in [3, 5)|x) \tag{32}$$

$$p_4(x) = P(T \in [5, \infty)|x) \tag{33}$$

생존함수 근사

$$S(t|x) = P(T > t|x) = 1 - P(T \leq t|x) \tag{34}$$

$$S(t|x) \approx 1 - \sum_{i:\tau_i \leq t} p_i(x) \tag{35}$$

- $\{p_i(x)\}_{i=1}^m$: 각 시간 구간에 대한 사건 발생 확률의 집합.
- $P(T > t|x)$: 시점 t까지 사건이 발생하지 않을 확률.
- $P(T \leq t|x)$: 시점 t 이전까지 사건이 발생했을 확률.
- 시점 t 이전에 사건이 발생했을 확률을 시점 t 이전의 각 구간에서 사건이 발생했을 확률들을 모두 더하는 것으로 근사.

생존함수 근사 예시

$$\tau_1 = 0,\ \tau_2 = 1,\ \tau_3 = 3,\ \tau_4 = 5,\ \tau_5 = \infty \tag{36}$$

$$p_i(x) = P(T \in [\tau_i, \tau_{i+1}) | x) \tag{37}$$

$$p_1(x) = 0.1,\ p_2(x) = 0.2,\ p_3(x) = 0.3,\ p_4(x) = 0.4 \tag{38}$$

$$S(t|x) \approx 1 - \sum_{i:\tau_i \le t} p_i(x) \tag{39}$$

$$S(3|x) \approx 1 - [p_1(x) + p_2(x)] = 1 - (0.1 + 0.2) = 0.7 \tag{40}$$

TabSurv(LS)

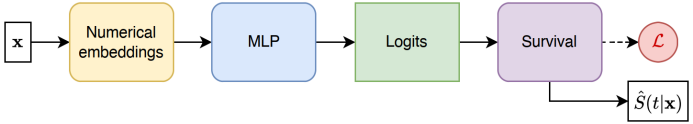


그림 1: TabSurv(LS)

- 사건의 시간 분포를 미리 가정하지 않는 비모수적 방법
- MLP, RealMLP와 같은 표 형태 딥러닝 모델 사용
- 각 이산 시간 구간에서 사건 발생 여부에 대한 로짓값 z_i 출력
- 로짓값은 $-\infty \leq z_i \leq \infty$이기에 Softmax로 구간별 확률 $\hat{p}_i(x)$로 변환
- 이후 시간 구간별 확률들을 누적해 생존함수 계산

TabSurv(LAS)

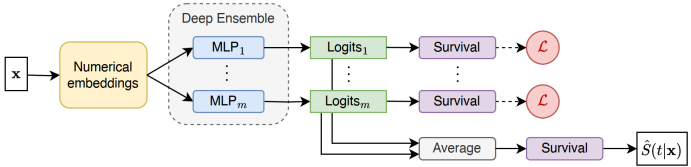


그림 2: TabSurv(LAS)

- 일반화 성능 향상 위해 여러 개의 독립적인 MLP를 사용하는 앙상블 구조.
- 동일한 특징 표현 사용하여 안정적, 효율적으로 학습.
- 학습은 독립적으로 수행되며 추론 시에만 예측 평균값 사용.

TabSurv(WSA)

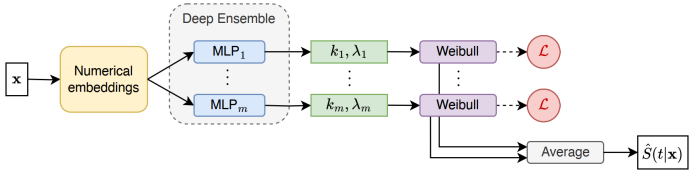


그림 3: TabSurv(WSA)

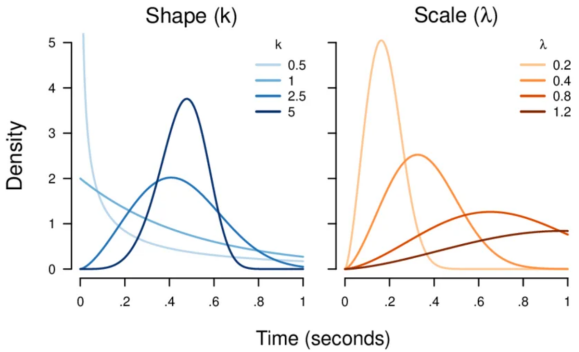
- 사건 발생 시간이 Weibull 분포를 따른다고 가정하는 모수적 생존분석 모델.
- 비모수적 모델을 사용할 경우 추정이 불안정할 수 있음.
- 두 가지 파라미터로 위험 패턴 표현이 가능해 유연하고 효율적인 모델.
- 각 모델이 파라미터를 예측하고 생존함수를 계산한 후 생존함수들을 평균냄.

Weibull CDF

$$F_W(t;\lambda,k) = 1 - \exp\left[-\left(\frac{t}{\lambda}\right)^k\right] \tag{41}$$

- $F_W(t;\lambda,k)$: 시점 t까지 사건이 발생했을 누적확률.
- t: 관측한 시간.
- λ: 사건 발생 시점을 전체적으로 조절하는 파라미터.
- k: 시간에 따른 위험 패턴을 조절하는 파라미터.

Weibull 분포



- λ 값이 커질수록 사건이 전반적으로 늦게 발생($\lambda > 0$).
- $k < 1$인 경우 초기 위험 높고 점점 감소, $k = 1$인 경우 시간이 지나도 위험 변화 적음, $k > 1$인 경우 시간이 지날수록 위험 증가($k > 0$).

Weibull 생존 함수

$$S_W(t) = P(T > t) = \exp\left[-\left(\frac{t}{\lambda}\right)^k\right] \tag{42}$$

- S_W: 사건이 시점 t까지 발생하지 않을 확률.
- t: 관측한 시간.
- λ: 사건 발생 시점을 전체적으로 조절하는 파라미터.
- k: 시간에 따른 위험 패턴을 조절하는 파라미터.

구간 사건 확률과 생존 확률

$$\hat{p}_i(x) = F_W(\tau_{i+1}) - F_W(\tau_i) \tag{43}$$

$$\hat{S}_i(x) = 1 - \sum_{j=1}^{i} \hat{p}_j(x) \tag{44}$$

- 특정 시간 구간 $[\tau_i, \tau_{i+1})$에서 사건이 발생할 확률 계산.
- 누적분포함수(CDF)의 차이를 이용하여 구간 확률 $\hat{p}_i(x)$ 계산 가능.
- 시간 구간별 사건 발생 확률을 누적하여 생존확률 계산.
- 사건 발생 확률이 커질수록 생존확률은 감소.

TabSurv(WAS)

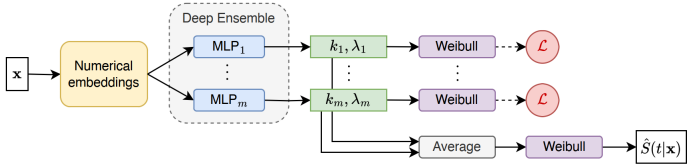


그림 4: TabSurv(WAS)

- 각 모델이 만든 Weibull 파라미터를 평균낸 뒤 생존함수 계산.
- WSA는 생존 함수를 평균내어 유연성이 높으나 모델 간 노이즈 반영 가능.
- WAS는 평균 파라미터를 써서 하나의 생존함수를 생성해 더 안정적인 예측 가능.

Discretized Likelihood

$$\ell(x,t,\delta) = \begin{cases} -\log \hat{p}_{I(t)}(x), & \delta = 1 \\ -\log \hat{S}_{I(t)}(x), & \delta = 0 \end{cases} \tag{45}$$

$$I(t) = \max\{i | \tau_i \leq t\} \tag{46}$$

- $I(t)$: 관측한 시간이 어느 시간 구간에 들어가는지 나타내는 함수.
- $\hat{p}_{I(t)}$: 사건이 발생했을 때 $I(t)$번째 시간 구간에서 사건이 발생할 확률.
- $\hat{S}_{I(t)}(x)$: 중도절단인 경우 $I(t)$번째 시간 구간까지 사건이 발생하지 않을 확률.
- 사건 발생 부분은 각 시간 구간을 class로 보는 크로스 엔트로피 형태

SurvHL

$$\ell(x,t,\delta) = \begin{cases} -\sum_{j=1}^{m} w_j(I(t)) \log(\hat{p}_j), & \delta = 1 \\ -\log \hat{S}_{I(t)}(x), & \delta = 0 \end{cases} \tag{47}$$

$$L = \frac{1}{n} \sum_{i=1}^{n} \ell(x_i, t_i, \delta_i) \tag{48}$$

- 기존 Discretized Likelihood는 실제 사건이 발생한 하나의 구간만 학습.
- 실제 구간 주변의 인접 구간들도 $\omega_j(I(t))$를 통해 주변 구간에 Gaussian 기반 가중치 부여.
- 예측이 인접 구간에 위치해도 일부 정답으로 인정하여 안정적으로 학습.

Discretized Likelihood 예시

$$(0, 0, 1, 0, 0) \tag{49}$$

- 기존 방식은 one-hot 형식의 정답

$$w(I(t)) = (0, 0.2, 0.6, 0.2, 0) \tag{50}$$

- 정답 구간 주변에 정답 weight를 나눠 가까운 구간도 일부 정답으로 인정

튜닝 결과 성능

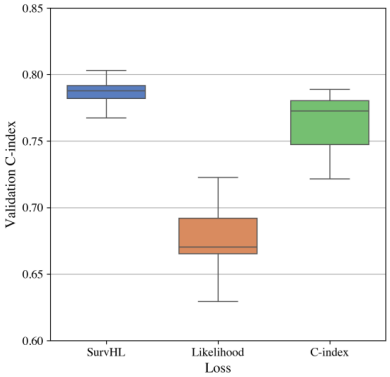


그림 5: 튜닝 결과 성능

- 기존 우도 손실함수 기반 튜닝, C-Index 기반 튜닝, SurvHL 기반 튜닝 시 SurvHL 방식이 일관되게 높은 검증 성능 보임.

평가지표

$$C = \frac{\sum_{(i,j)\in\mathcal{J}} \mathbf{1}[\hat{t}_i < \hat{t}_j]}{|\mathcal{J}|} \tag{51}$$

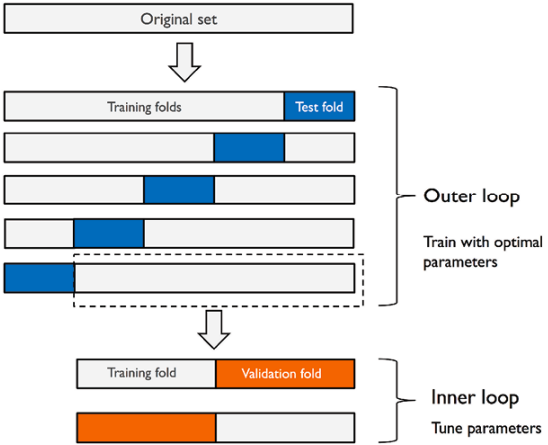
$$IBS = \frac{1}{t_{\max}} \int_0^{t_{\max}} \mathbb{E}\left[\left(\Delta_{\text{new}}(t) - \hat{S}(t|\mathbf{x}_{\text{new}})\right)^2\right] dt \tag{52}$$

- C-index C: 전체 비교 가능한 대상 쌍 중 사건 발생 순서를 맞춘 비율(1이면 완벽한 순위화, 0.5이면 무작위)
- IBS: 각 시점에서의 사건 미발생 여부와 예측한 생존확률 간 차이의 평균 제곱 오차(0에 가까울수록 정확히 예측)

실험 설정

- 사건 발생 비율 및 중도절단 비율을 기반으로 stratified split 수행.
- Optuna를 사용해서 모델마다 50∼200번 하이퍼파라미터 튜닝 실행.
- C-Index 최대화 기준으로 하이퍼파라미터 튜닝 실행.
- 하이퍼파라미터를 선택 후 시드를 바꾸어 20번 수행해 성능 평균냄.
- Nested cross validation은 계산량이 많아 수행하지 않음.

Nested Cross Validation



데이터셋

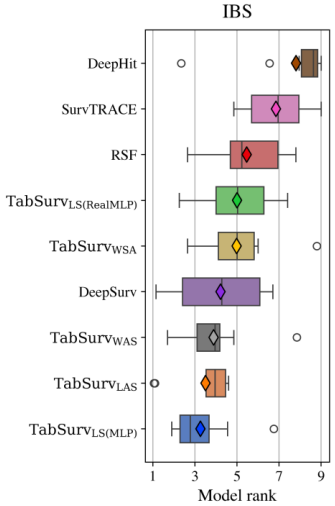
데이터셋	샘플 수			변수 개수		위험
	Train	Validation	Test	Numeric	Categorical	
METABRIC	999	333	572	494	75	42%
SEER	2112	704	1208	4	21	15%
SUPPORT	4779	1594	2732	37	30	68%
TCGA-GBM	312	105	179	5	20	82%
Rotterdam	1565	522	895	5	6	43%
FLC	4133	1378	2363	4	34	28%
GBSG2	360	120	206	5	4	44%
WHAS500	262	88	150	6	8	43%
Lung	119	40	69	3	4	72%
PBC	219	73	126	11	15	39%

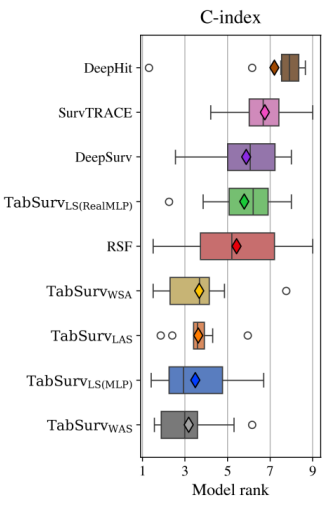
표 1: 생존 분석 데이터셋 요약표

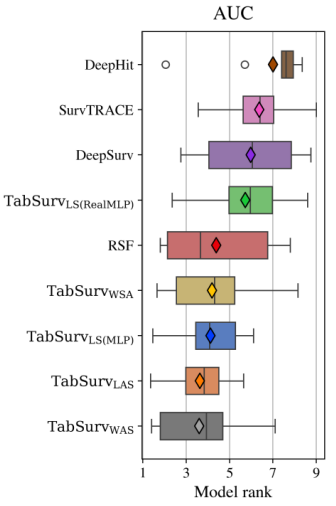
데이터셋 순위 기반 비교

- 모든 데이터셋에 대해 평가지표별 순위 계산.
- 평가지표별 각 모델의 모든 데이터셋에 대한 평균 순위 계산.
- 평균 순위가 낮을수록 전반적으로 성능이 좋은 모델.
- 각 모델의 Rank를 Box plot으로 그려 데이터셋별 안정성 확인.

데이터셋 순위 기반 비교


IBS
DeepHit
SurvTRACE
RSF
TabSurv$_{LS(RealMLP)}$
TabSurv$_{WSA}$
DeepSurv
TabSurv$_{WAS}$
TabSurv$_{LAS}$
TabSurv$_{LS(MLP)}$
1 3 5 7 9
Model rank


C-index
DeepHit
SurvTRACE
DeepSurv
TabSurv$_{LS(RealMLP)}$
RSF
TabSurv$_{WSA}$
TabSurv$_{LAS}$
TabSurv$_{LS(MLP)}$
TabSurv$_{WAS}$
1 3 5 7 9
Model rank


AUC
DeepHit
SurvTRACE
DeepSurv
TabSurv$_{LS(RealMLP)}$
RSF
TabSurv$_{WSA}$
TabSurv$_{LS(MLP)}$
TabSurv$_{LAS}$
TabSurv$_{WAS}$
1 3 5 7 9
Model rank

앙상블 결과

$P(A > B)$	LS	LAS	LS Ens	DeepSurv	DS Ens	DH Ens
LS	0.000	0.225	0.162	0.978	0.564	0.926
LAS	0.011	0.000	0.049	0.910	0.502	0.941
LS Ens	0.161	0.112	0.000	0.967	0.835	0.972
DeepSurv	0.000	0.000	0.000	0.000	0.000	0.059
DS Ens	0.002	0.124	0.008	0.851	0.000	0.907
DH Ens	0.001	0.026	0.001	0.168	0.024	0.000

그림 6: 성능 비교표

- 베이지안 방식으로 각 모델이 다른 모델보다 더 좋을지 확률 계산.
- 기존 DeepSurv나 DeepHit 모델 등을 여러 개 독립적으로 학습해 앙상블.
- 모델 여러 개를 평균내서 강한 것이 아니라 TabSurv 구조가 효과적.

XGBoost와의 비교

Baseline	Metric	Better	ROPE	Worse
XGBSEKaplanNeighbors	C-index	0.567	0.254	0.179
XGBSEKaplanNeighbors	IBS	0.293	0.605	0.102
XGBSEKaplanNeighbors	AUC	0.796	0.140	0.064
XGBSEStackedWeibull	C-index	0.254	0.742	0.004
XGBSEStackedWeibull	IBS	0.968	0.032	0.000
XGBSEStackedWeibull	AUC	0.427	0.417	0.156

그림 7: 성능 비교표

- 베이지안 방식으로 TabSurv 모델이 XGBoost 모델보다 더 좋을지 확률 계산.
- 최소 XGBoost 기반 생존모델 수준이거나 그 이상의 성능을 보일 확률 높음.
- 특히 Weibull 기반 기법이 IBS에서 강했음.

추가 분석

- WAS는 데이터가 조금 부족해도 분포 기반으로 c-index 성능 높았음.
- 발생 시간 분포가 복잡한 경우 Weibull 분포 가정보다는 비모수적 방법 우세.
- LS는 구조가 단순해 작은 데이터에서도 안정적으로 동작.
- LAS는 데이터 큰 경우 성능 높음.
- 다른 생존분석에 쓰이는 분포로 바꿔서도 사용 가능.
- 단순히 앙상블 때문에 모델 성능이 높은 것은 아님.

결론

- Survival Histogram Loss 기반의 표 형식 생존분석 프레임워크 TabSurv 제안
- 다양한 생존분포 모수화 및 집계 전략(LAS, WAS, LS 등)을 포함하는 구조
- 다양한 실제 생존 데이터셋에서 기존 방법 대비 우수한 성능 확인
- LAS와 LS(MLP)는 낮은 IBS를 보여 생존확률 추정에 강점
- WAS는 높은 C-index와 time-dependent AUC를 보여 사건 발생 순위화에 강점
- 복잡한 backbone(RealMLP)이 항상 성능 향상으로 이어지지는 않음
- WAS 구조는 noise smoothing 효과로 인해 WSA보다 안정적인 성능

감사합니다.