중앙대학교

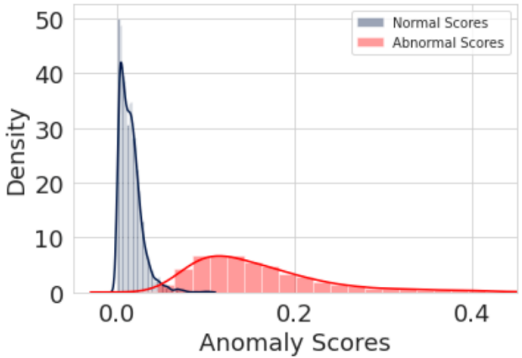
DyC-CLIP: Dynamic context-aware multi-modal prompt learning for zero-shot anomaly detection

서정호

응용통계학과
(중앙대학교)

2026년 08월 14일

기존 이상 탐지



- 이상 데이터는 매우 적고 다양한 형태를 띄기에 학습에 충분한 샘플 수집 어려움
- 이상 탐지는 정상 샘플만을 이용해 학습하고 그 분포와의 차이를 이용해 이상 식별

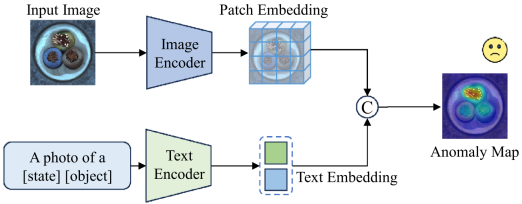
기존 이상 탐지의 한계

- 사전학습된 모델을 통한 추출한 임베딩 기반 이상 탐지 기법 존재
- 하지만 사전학습된 도메인과 데이터 간 차이로 인해 성능은 제한적일 수 있음
- 재구성 오차를 기반으로 이상 탐지하는 재구성 기반 방법도 존재
- 두 방법 모두 일반화 성능 향상 위해서는 대량의 고품질 정상 데이터 필요
- 이전에 관측된 적 없는 범주에 대해서는 탐지 제한적

제로샷 이상 탐지

- 기존 이상 탐지 방법은 특정 작업에 맞는 데이터셋을 사용해 학습
- 학습 데이터와 테스트 데이터에 큰 변화가 있는 경우 활용 제한
- 보조 데이터셋을 이용해 일반화된 모델 학습 후 관측된 적 없는 범주에서 이상 탐지하는 제로샷 이상 탐지 주목받고 있음
- VLM 모델인 CLIP은 텍스트도 활용 가능해 일반화 성능이 높아 많이 사용됨
- WinCLIP, AnomalCLIP, AdaCLIP, Filo, ClipSAM 등 활용됨

프롬프트 학습

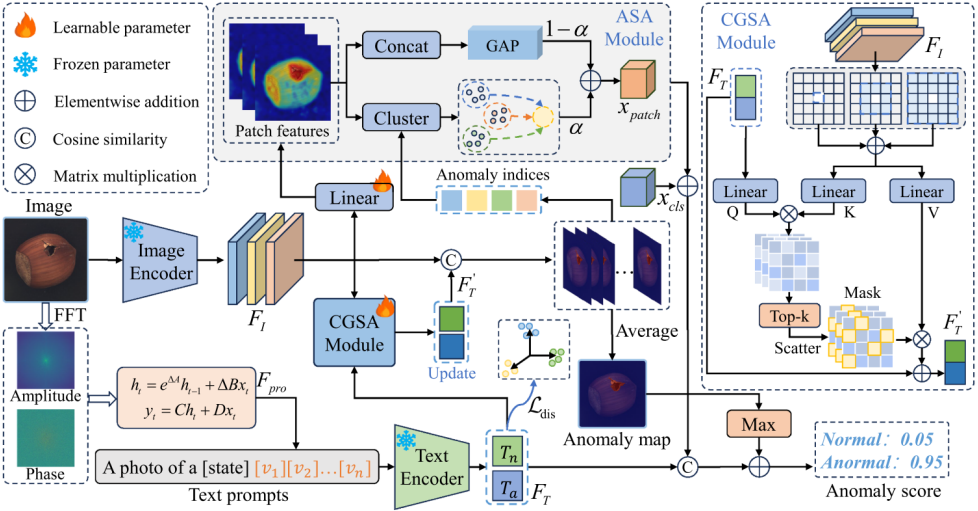


- CLIP은 텍스트 프롬프트와 이미지 패치 특징과의 유사도를 계산해 픽셀 수준 이상 맵 생성
- CLIP 기반 방법에서는 텍스트 프롬프트 설계가 성능에 큰 영향 미침
- 그러나 모든 이미지에 동일한 문장과 표현을 사용하여 표현에 한계 존재
- 사람이 프롬프트를 만드는 대신 적절한 표현을 학습하도록 하는 프롬프트 학습 등장

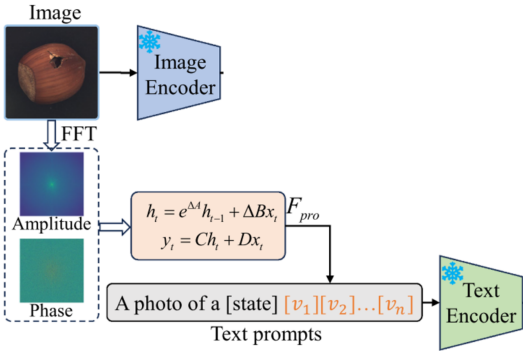
프롬프트 학습

- 모델에게 주는 프롬프트를 사람이 전부 직접 작성하는 대신 일부를 모델이 학습 가능한 벡터로 바꿈
- 예: a photo of damaged bottle $->$ $[v_1]$ $[v_2]$ damaged bottle
- 이를 통해 사람이 만든 문장만 사용하는 것보다 유연한 표현 생성 가능
- CoCoOp, VCP-CLIP은 이미지 특징을 텍스트 프롬프트에 반영하지만 전역 이미지 정보 포착에는 한계
- 패치 영역을 독립적으로 보기에 주변 패치 정보 반영 제한

전체 프레임워크


Learnable parameter
Frozen parameter
Elementwise addition
Cosine similarity
Matrix multiplication
Image
FFT
Amplitude
Phase
Image Encoder
Patch features
Concat
GAP
Cluster
ASA Module
Anomaly indices
Linear
CGSA Module
Update
Average
Anomaly map
Max
Normal: 0.05
Anormal: 0.95
Anomaly score
Text Encoder
A photo of a [state] [v1][v2]...[vn]
Text prompts
Q
K
V
Mask
Top-k
Scatter

Dynamic Adaptaion



- 푸리에 변환으로 얻은 진폭, 위상 스펙트럼을 Vision Mamba에 통과시킨 후 Concat
- 이를 통해 구한 특징을 프롬프트에 있는 학습 가능한 토큰에 더함

FDA

$$\mathcal{A}_{u,v} = \sqrt{\mathrm{Re}(\mathcal{F}_{\mathrm{u,v}})^2 + \mathrm{Im}(\mathcal{F}_{\mathrm{u,v}})^2} \tag{1}$$

$$\mathcal{P}_{u,v} = \arctan\left(\frac{\mathrm{Im}(\mathcal{F}_{\mathrm{u,v}})}{\mathrm{Re}(\mathcal{F}_{\mathrm{u,v}})}\right) \tag{2}$$

- $\mathcal{F}_{u,v}$: 푸리에 변환으로 입력 이미지 $I \in \mathbb{R}^{H\times W\times 3}$에서 얻은 주파수 영역 표현, u, v는 주파수 영역에서의 좌표
- $\mathcal{A}_{u,v}, \mathcal{P}_{u,v}$: 주파수 성분이 얼마나 강하게 존재하는지 의미하는 진폭 스펙트럼, 주파수 성분이 공간적으로 어떻게 배치되어 있는지 의미하는 위상 스펙트럼
- $\mathrm{Re}(\cdot), \mathrm{Im}(\cdot)$: $\mathcal{F}_{u,v}$의 실수부와 허수부

SSM

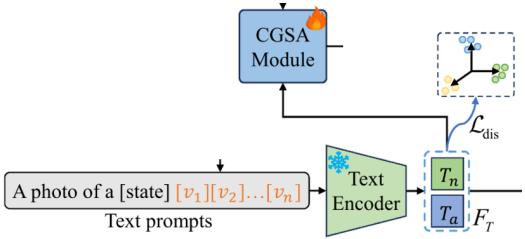
$$\tilde{\mathcal{A}}_{u,v} = \text{Vision Mamba}(\mathcal{A}_{\text{u,v}}) \tag{3}$$

$$\tilde{\mathcal{P}}_{u,v} = \text{Vision Mamba}(\mathcal{P}_{\text{u,v}}) \tag{4}$$

$$\mathcal{F}_{pro} = Cat(\tilde{\mathcal{A}}_{u,v}, \tilde{\mathcal{P}}_{u,v}) \tag{5}$$

- 진폭 스펙트럼을 전역적인 구조 특징으로, 위상 스펙트럼을 경계 정보로 사용해 더 높은 판별력을 갖는 특징 공간 생성
- 진폭과 위상 스펙트럼 정보는 얻었으나 그 정보 사이 관계를 학습하지는 않음
- Vision Mamba로 주파수 특징의 장거리 의존성을 학습해 더 많은 정보 표현

FDA



- 정상, 이상 상태가 입력된 프롬프트를 텍스트 인코더에 넣어 정상/이상 임베딩을 얻음
- 이후 둘을 concat해 이미지 레벨에서의 정보를 구함

프롬프트 생성

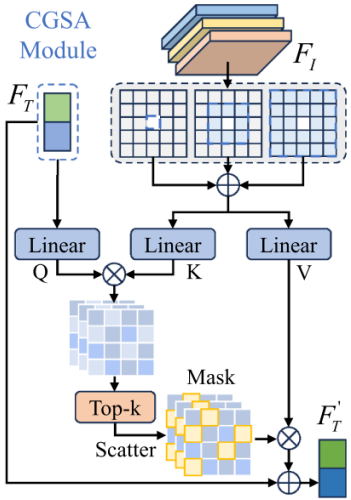
$$p(f, v) = [p_1(f_1, v_1), p_2(f_2, v_2), \cdots, p_n(f_n, v_n),] \tag{6}$$

$$p_i(f_i, v_i) = f_i + v_i \tag{7}$$

$$\{f_i\}_{i=1}^{n} = F_{pro} \tag{8}$$

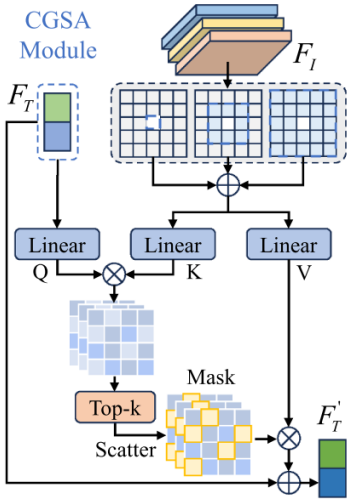
- "a photo of a [state] $[v_1]$ $[v_2]$ $\cdots$ $[v_i]$"
- state: 객체의 상태를 나타내는 표현(예: good, damaged)
- $v_i, i \in \{1, 2, \cdots, n\}$: 객체 범주에 해당하는 학습 가능한 임베딩 벡터
- 주파수 영역 특징 F_{pro}는 객체 범주 임베딩 벡터 v_i와 결합

CGSA



- 각 이미지에 구한 주파수 영역 특징을 프롬프트에 사용하면 텍스트 임베딩에 변화가 생김
- 이상 위치 추정 과제에서 각 이미지별 패치 특징과 텍스트 임베딩 정렬이 어려워짐
- 이를 위해 이미지 특징을 이용해 텍스트 임베딩을 조정하는 CGSA 사용

CGSA



- F_T: 정상 텍스트 임베딩 T_n과 비정상 텍스트 임베딩 T_a를 Concat한 텍스트 특징
- $F_I^l \in \mathbb{R}^{HW \times D}$: 이미지 인코더의 l번째 레이어에서 추출된 패치 특징의 모음
- $F_I^{l'}$: F_I^l에 대해 다양한 스케일의 $r \times r$ 평균 풀링을 적용하고 결과를 융합해 만든 패치 특징

Scaled Dot-product Attention

$$Q_T = F_T W_T, K_I^l = F_I^{l'} W_I^K, V_I^l = F_I^{l'} W_I^V \tag{9}$$

$$\frac{Q_T (K_I^l)^T}{\sqrt{C}} \tag{10}$$

- $F_T \in \mathbb{R}^{2\times C}, F_T' \in \mathbb{R}^{2\times C}$: 텍스트 임베딩, CGSA로 정제된 텍스트 임베딩
- $Q_T \in \mathbb{R}^{2\times C}, K_I^l \in \mathbb{R}^{HW\times C}, V_I^l \in \mathbb{R}^{HW\times C}$: 텍스트 쿼리, l번째 레이어 이미지 키, l번째 레이어 이미지 값
- $Q_T (K_I^l)^T$: 텍스트와 이미지 패치 사이 내적, 서로의 관련성
- $\sqrt{C}$: 임베딩 차원이 커질수록 내적값이 커질 수 있기에 안정화를 위해 나눔

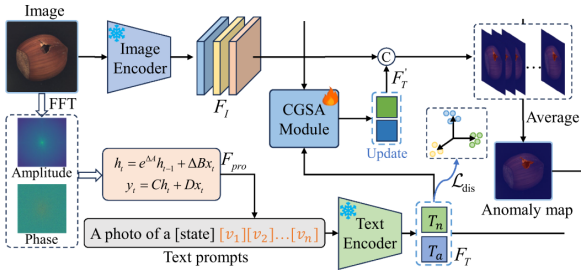
희소 어텐션

$$F_T' = F_T + \text{softmax}\left(\mathcal{T}_k\left(\frac{Q_T(K_I^l)^T}{\sqrt{C}}\right)\right) V_I^l \tag{11}$$

$$[\mathcal{T}_k(A)]_{ij} = \begin{cases} A_{ij}, & A_{ij} \in \text{top}-\text{k} \\ 0, & \text{otherwise} \end{cases} \tag{12}$$

- $F_I^{l'}$에는 이미지의 모든 패치 정보가 있으나 모든 정보가 필요하지는 않음
- $\mathcal{T}(\cdot)$: 모든 패치에 대해 attention score를 구한 후 중요한 상위 점수만 유지하는 연산
- 정상, 이상 텍스트와 각 이미지 패치 관련도 계산 후 중요한 Top-k 관련도만 남김
- 이후 softmax를 사용하여 attention score를 상대적인 가중치로 바꾼 후 V_I^l에 곱해 이미지 정보를 구하고 텍스트 임베딩에 더함

이상 맵



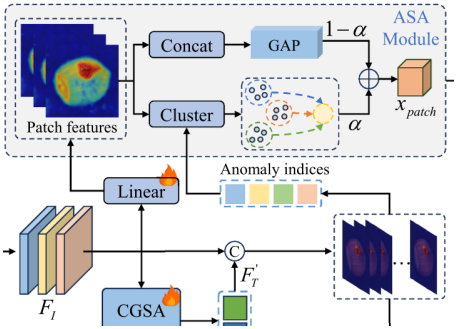
- 이미지 인코더에서 구한 여러 레이어에서의 이미지 패치 임베딩 F_I^l
- FFT, Vision Mamba를 통해 구한 이미지 전역 특징을 반영한 텍스트 임베딩 F_T
- 여러 레이어에서의 임베딩을 CGSA를 통해 주변 패치 반영한 이미지 패치 임베딩 $F_I^{l'}$
- CGSA를 통해 구한 이미지 패치 임베딩으로 업데이트된 텍스트 임베딩 F_T'

이상 맵

$$M_I^l = \mathrm{softmax}\left(\frac{\mathrm{Up}\left(\tilde{F}_I^l(\tilde{F}_T')^T\right)}{\tau}\right) \tag{13}$$

- $(\tilde{\cdot})$: 임베딩 벡터 차원에 대한 L2 정규화
- $\tilde{F}_I^l(\tilde{F}_T')^T$: 정규화한 두 벡터의 내적으로 각 패치와 정상, 이상 텍스트와의 코사인 유사도 계산
- $Up(\cdot)$: Bilinear Interpolation을 통한 업샘플링 연산
- τ: 정상, 이상 구분 강도를 조절하는 하이퍼파라미터
- 모든 L개의 계층에서 생성된 Anomaly map의 평균으로 최종 anomaly map을 계산

ASA



- 기존 이상 점수는 이상 맵의 최대값에 의존하기에 패치 수준 예측에 민감
- 이상 패치 특징을 집계해 신뢰성 높은 이상 점수 생성
- 이미지 인코더의 여러 레이어에서 패치 특징을 가져옴
- 이상 가능성이 높은 패치 요약 부분과 전체 패치 평균내어 요약하는 이중 구조

이상 패치 요약

$$x_k = \frac{1}{k}\sum_{j=1}^{k} c_j \tag{14}$$

- Anomaly map을 기반으로 이상 점수가 높은 패치 임베딩을 후보 이상 패치로 가져옴
- 후보 이상 패치들을 K-Means를 통해 k개의 군집으로 묶음
- c_j: 각 군집에 대한 중심점
- 이상 패치 임베딩 군집 중심점의 평균으로 이상 특징 요약

전체 패치 요약

$$x_g = GAP(Concat(F_I^1, F_I^2, \cdots, F_I^L)) \tag{15}$$

- 여러 레이어에서 추출된 패치 특징 F_I^l을 Concat
- 패치가 여러 레이어의 동일한 위치에서 가지는 정보를 하나의 특징 벡터로 통합
- 모든 위치의 패치 특징을 평균 내어 전역 패치 표현 생성
- 특정 이상 후보가 아닌 이미지 전체 패치 정보를 활용

가중 융합

$$x_{patch} = \alpha x_k + (1 - \alpha) x_g \tag{16}$$

$$x_c = x_{cls} + x_{patch} \tag{17}$$

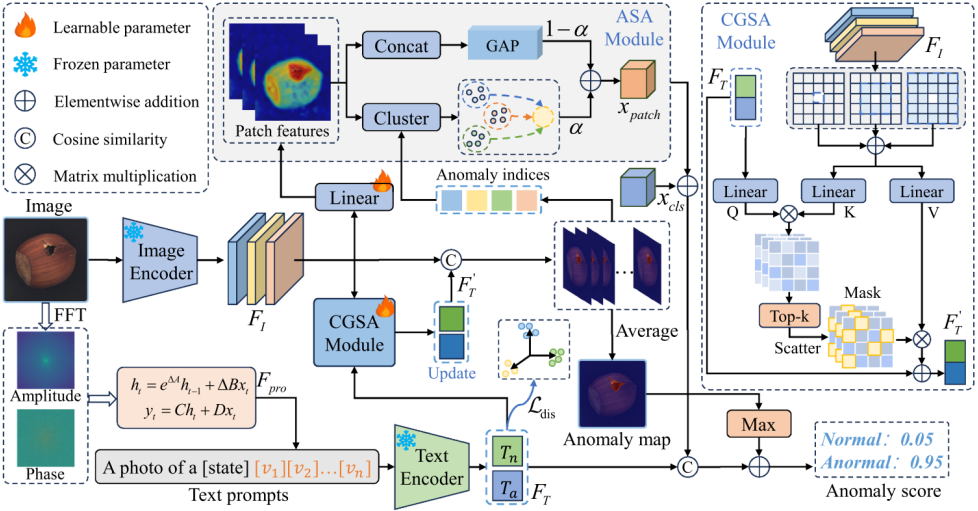
- x_k: 이상 후보 패치 요약 표현
- x_g: 이미지 전체 패치 요약 표현
- α: 두 표현의 중요도 조절하는 하이퍼파라미터
- x_{cls}: CLIP 이미지 인코더의 전체 이미지 표현
- ASA에 CLS 토큰을 더해 전역 정보와 이상 패치 관련 정보 모두 표현

최종 이미지 수준 이상 점수

$$S = S_I + S_P \tag{18}$$

- S_I: x_c와 텍스트 임베딩 사이의 유사도를 구한 이상 점수
- S_P: Anomaly map M에서 가장 큰 값
- 이미지 전체를 텍스트와 비교해서 의미적으로 얼마나 비정상인지 구함
- 이미지 안에서 가장 이상한 것 같은 곳은 얼마나 강하게 이상으로 예측되었는지 구함
- 단순히 anomaly map의 최대값에 의존하는 것이 아닌 전체적인 표현도 반영

전체 프레임워크


Learnable parameter
Frozen parameter
Elementwise addition
Cosine similarity
Matrix multiplication
Image
FFT
Amplitude
Phase
Image Encoder
Patch features
Concat
GAP
Cluster
ASA Module
Anomaly indices
Linear
CGSA Module
Update
Average
Anomaly map
Max
Normal: 0.05
Anormal: 0.95
Anomaly score
Text Encoder
A photo of a [state] [v1][v2]...[vn]
Text prompts
CGSA Module
Linear
Q
K
V
Mask
Top-k
Scatter

전역 손실

$$\mathcal{L}_{global} = BCE(S_{gt}, p_a(x_c, F_T)) \tag{19}$$

- BCE: 이진 교차 엔트로피
- S_{gt}: 이미지 정답 레이블
- p_a: 이미지 이상 확률
- x_c: 이미지 임베딩
- F_T: 텍스트 임베딩
- 이미지가 정상인지 아닌지 구분하기 위한 손실

지역 손실

$$\mathcal{L}_{local} = \sum_{l} Focal(Up(M_I^l), Y) + \sum_{l} DICE(Up(M_I^l), Y) \tag{20}$$

- $Y \in \mathbb{R}^{H \times W}$, M_I^l: 픽셀 수준 정답 마스크, l번째 특징 계층에서 생성된 이상 맵
- $Up(\cdot)$: 이상 맵을 정답 마스크 크기 $H \times W$로 변환하는 업샘플링 연산
- Focal: p_t가 낮은 오분류 픽셀 손실을 $(1-p_t)^\gamma$로 강조해 어려운 픽셀 이상 판별 향상
- Dice: $2\sum_i p_i y_i$로 예측과 정답의 겹침을 측정하고, 이를 최대화하여 이상 영역의 위치와 크기를 정답 마스크에 가깝게 학습

분리 손실

$$\mathcal{L}_{dis} = |\langle T_n, T_a \rangle|^2 \tag{21}$$

- T_n: 정상 상태 텍스트 임베딩
- T_a: 이상 상태 텍스트 임베딩
- 정상과 이상 텍스트 표현 판별력을 높이기 위한 정규화 손실
- 두 텍스트 임베딩 사이의 내적이 0이 되도록, 직교하도록 유도해 서로 분리되도록 학습

전체 손실

$$\mathcal{L}_{total} = \mathcal{L}_{global} + \mathcal{L}_{local} + \lambda \mathcal{L}_{dis} \tag{22}$$

- $\mathcal{L}_{global}$: 이미지 수준 정상/이상 판별 학습
- $\mathcal{L}_{local}$: 픽셀 수준 이상 위치 추정 학습
- $\mathcal{L}_{dis}$: 정상/이상 텍스트 임베딩의 분리 유도
- λ: 분리 손실의 기여도를 조절하는 하이퍼파라미터

데이터셋

- 제로샷 이상 탐지 성능 평가 위해 14가지 이상 탐지 데이터셋에 대해 실험
- 산업 데이터셋: MVTec-AD, VisA, BTAD, KSDD2, DAGM, DTD-Synthetic
- 의료 데이터셋: Br35H, BrainMRI, HeadCT, Kvasir, CVC-ColonDB, CVC-ClinicDB, Endo, ISIC
- 기본적으로 VisA를 학습 데이터로 사용, VisA를 평가할 때는 MVTec-AD로 학습

평가지표

- AUROC: $P(s_a > s_n)$, 이상 이미지(픽셀)의 점수가 정상 이미지(픽셀)의 점수보다 높게 나오는 정도
- AP: 이상 점수가 높은 순으로 정렬한 뒤, 실제 이상이 나타나는 각 지점까지의 예측 중 실제 이상이 차지하는 비율을 계산하여 평균
- F1-Max: $\max_t \frac{2TP(t)}{2TP(t)+FP(t)+FN(t)}$: 정상, 이상을 나누는 모든 기준값 t 중 올바른 이상 탐지는 많고 오탐과 미탐은 적은 최적 성능
- PRO: $\frac{1}{K}\sum_{k=1}^{K}\frac{|R_k \cap P|}{|R_k|}$: 각 실제 이상 영역 R_k 중 모델이 이상으로 검출한 영역 P가 차지하는 비율을 영역별로 평균

기타 설정

- ViT-L/14-336 기반 CLIP 활용
- 패치 수준 특징: (6, 12, 18, 24)번째 트랜스포머 계층에서 추출
- 집계 범위: (1, 3, 5)
- 학습 가능한 클래스별 토큰 길이: 2
- CGSA Top k 비율: 5/6
- 분리 손실 가중치: 0.5
- 가중 계수: 0.2
- 학습, 추론 시 입력 이미지 크기: 518×518
- 학습: Adam, $lr = 2 \times 10^{-4}$, 배치 사이즈 32, 20에포크
- 단일 NVIDIA A100(80GB)에서 실험

정량적 결과

Metric	Dataset	WinCLIP CVPR2023	APRIL-GAN CVPRw2023	CLIP-AD IJCAI2024	AnomalyCLIP ICLR2024	Ada-CLIP ECCV2024	AA-CLIP CVPR2025	DyC-CLIP —
Image-level (AUROC,F1-Max, AP)	MVTec AD	(91.8, *92.9*, 95.1)	(86.1, 90.4, 93.5)	(89.8, 91.1, 95.3)	(91.5, 92.8, 96.2)	(*92.0*, 92.7, *96.4*)	(90.5, 91.4, 95.6)	(**92.1**, **93.2**, **96.6**)
	VisA	(78.1, 79.0, 77.5)	(78.0, 78.7, 81.4)	(79.8, 79.2, 84.3)	(82.1, 80.4, *85.4*)	(83.0, *81.6*, 84.9)	(*84.6*, 78.7, 83.4)	(**87.2**, **84.1**, **89.8**)
	BTAD	(83.3, 81.0, 84.1)	(74.2, 70.0, 71.7)	(85.8, 81.7, 85.2)	(89.1, 86.0, 91.1)	(91.6, 88.9, 92.4)	(**93.8**, *92.8*, *97.1*)	(*93.2*, **94.5**, **97.4**)
	KSDD2	(93.5, 71.4, 77.9)	(90.3, 70.2, 74.4)	(95.2, 84.4, 88.2)	(92.1, 71.0, 77.8)	(*95.9*, 84.5, 95.9)	(95.8, *91.4*, *96.8*)	(**96.4**, **91.8**, **97.1**)
	DAGM	(89.6, 86.4, 90.4)	(94.4, 83.9, 80.2)	(90.8, 88.4, 90.5)	(*97.5*, 90.2, *92.3*)	(96.5, **94.1**, **92.7**)	(94.3, 81.7, 84.2)	(**97.9**, *92.4*, **92.7**)
	DTD-Synthetic	(93.2, 94.3, 92.6)	(83.9, 89.4, 93.6)	(91.5, 91.8, 96.8)	(*93.5*, *94.5*, 97.0)	(92.8, 92.2, 97.0)	(91.4, 93.3, *97.2*)	(**94.4**, **95.2**, **98.3**)
	Average	(88.3, 84.2, 86.3)	(84.5, 80.4, 82.5)	(88.8, 86.1, 90.1)	(91.0, 85.8, 90.0)	(*92.0*, *89.0*, *93.2*)	(91.7, 88.2, 92.4)	(**93.5**, **91.9**, **95.3**)
Pixel-level (AUROC,PRO, AP)	MVTec AD	(85.1, 64.6, 18.0)	(87.6, 44.0, 40.8)	(89.8, 70.6, 40.0)	(91.1, *81.4*, 34.5)	(86.8, 33.8, 38.1)	(*91.9*, 61.9, *45.4*)	(**92.2**, **87.1**, **48.6**)
	VisA	(79.6, 56.8, 5.0)	(94.2, 86.8, 25.7)	(95.0, 86.9, 26.3)	(*95.5*, *87.0*, 21.3)	(95.1, 71.3, **29.2**)	(*95.5*, 46.3, 25.0)	(**95.6**, **90.3**, *28.6*)
	BTAD	(71.4, 32.8, 11.2)	(91.3, 23.0, 32.9)	(93.1, 59.8, **46.7**)	(93.3, *69.3*, 42.0)	(87.7, 17.1, 36.6)	(**96.1**, 34.4, *46.3*)	(*95.1*, **76.8**, **46.7**)
	KSDD2	(97.9, 91.2, 17.1)	(97.9, 51.1, *61.6*)	(99.3, 85.4, 58.9)	(99.4, *92.7*, 41.8)	(96.1, 70.8, 56.4)	(*99.5*, 68.8, 43.7)	(**99.6**, **98.6**, **71.5**)
	DAGM	(83.2, 55.4, 3.1)	(82.4, 66.0, 42.6)	(*96.5*, 83.1, 40.7)	(95.6, **91.0**, 29.5)	(91.5, 40.9, 44.2)	(96.3, 31.4, *45.9*)	(**96.7**, *88.2*, **46.2**)
	DTD-Synthetic	(83.9, 57.8, 11.6)	(96.6, 41.6, *67.3*)	(97.1, 68.7, 62.3)	(*97.9*, *92.3*, 52.4)	(94.1, 24.9, 52.8)	(96.4, 62.8, 62.8)	(**98.4**, **94.8**, **71.4**)
	Average	(83.5, 59.8, 11.0)	(91.7, 52.1, 45.2)	(95.1, 75.8, *45.8*)	(95.5, *85.6*, 36.9)	(91.9, 43.1, 42.9)	(*96.0*, 50.9, 44.9)	(**96.3**, **89.3**, **52.2**)

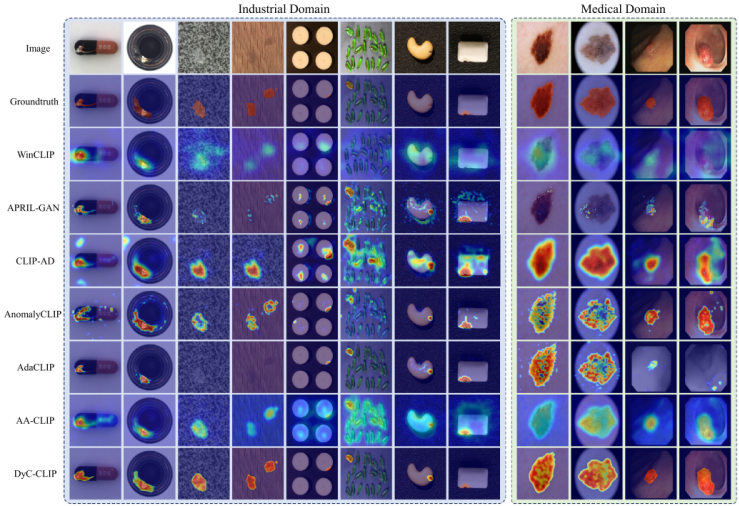
- 산업 환경 데이터에서 DyC-CLIP이 우수한 제로샷 이상 탐지 성능 보임

정량적 결과

Metric	Dataset	WinCLIP CVPR2023	APRIL-GAN CVPRw2023	CLIP-AD IJCAI2024	AnomalyCLIP ICLR2024	Ada-CLIP ECCV2024	AA-CLIP CVPR2025	DyC-CLIP —
Image-level (AUROC,F1-Max, AP)	HeadCT	(83.7, 78.8, 81.6)	(89.3, 82.0, 89.6)	(93.8, 90.5, 92.2)	(95.3, 89.7, 95.2)	(93.3, 86.5, 92.2)	(*96.8*, *93.4*, *95.3*)	(**98.1**, **94.4**, **97.7**)
	BrainMRI	(92.0, 84.2, 90.7)	(89.6, 85.3, 84.5)	(92.8, 88.7, 85.5)	(*96.1*, 92.3, 92.3)	(94.9, 90.4, *94.2*)	(94.1, *93.5*, 93.3)	(**96.2**, **94.8**, **96.8**)
	Br35H	(80.5, 74.1, 82.2)	(93.1, 85.4, 92.9)	(96.0, 90.8, 95.5)	(*97.3*, *92.4*, *96.1*)	(95.7, 89.1, 95.7)	(96.2, 91.5, 94.2)	(**97.6**, **94.0**, **97.1**)
	Average	(85.4, 79.0, 84.8)	(90.7, 84.2, 89.3)	(94.2, 90.0, 91.4)	(*96.2*, 91.5, *94.5*)	(94.6, 88.7, 94.0)	(95.7, *92.8*, 94.3)	(**97.3**, **94.4**, **97.2**)
Pixel-level (AUROC,PRO, AP)	ISIC	(83.3, 55.1, 62.4)	(85.8, 13.7, 69.8)	(81.6, 29.0, 65.5)	(88.4, 78.1, 74.4)	(85.4, 5.3, 70.6)	(**93.8**, *88.5*, *85.9*)	(*93.4*, **88.6**, **86.2**)
	ColonDB	(64.8, 28.4, 14.3)	(78.4, 28.0, 23.2)	(80.3, 58.8, 23.7)	(81.9, 71.4, 31.3)	(79.3, 6.5, 26.2)	(*83.6*, *76.9*, *32.1*)	(**83.8**, **77.1**, **34.7**)
	ClinicDB	(70.7, 32.5, 19.4)	(86.0, 41.2, 38.8)	(85.8, 69.7, 39.0)	(85.9, 69.6, 42.2)	(84.3, 14.6, 36.0)	(*89.5*, *79.7*, *56.5*)	(**90.1**, **80.1**, **57.0**)
	Endo	(68.2, 28.3, 23.8)	(84.1, 32.3, 47.9)	(85.6, 57.0, 51.7)	(86.3, 67.3, 50.4)	(84.0, 10.5, 44.8)	(*90.2*, *77.0*, *60.7*)	(**90.7**, **77.7**, **64.1**)
	Kvasir	(69.8, 31.0, 27.5)	(80.2, 27.1, 42.4)	(*82.5*, 48.1, 46.2)	(81.8, 53.8, 42.5)	(79.4, 12.3, 43.8)	(**87.6**, *60.9*, *57.2*)	(**87.6**, **61.3**, **60.2**)
	Average	(71.4, 35.1, 29.5)	(82.9, 28.5, 44.4)	(83.1, 52.5, 45.2)	(84.9, 68.0, 48.2)	(82.5, 9.8, 44.3)	(*89.0*, *76.6*, *58.5*)	(**89.1**, **77.0**, **60.4**)

- 의료 환경 데이터에서도 DyC-CLIP이 우수한 제로샷 이상 탐지 성능 보임

정성적 결과


Industrial Domain
Medical Domain
Image
Groundtruth
WinCLIP
APRIL-GAN
CLIP-AD
AnomalyCLIP
AdaCLIP
AA-CLIP
DyC-CLIP

각 요소의 영향

Method	MVTec-AD		VisA	
	Image-level	Pixel-level	Image-level	Pixel-level
w/o FDA	(91.5, 96.0)	(91.4, 47.9)	(86.5, 89.4)	(95.0, 28.0)
w/o CGSA	(91.3, 96.1)	(91.6, 47.5)	(86.7, 89.1)	(95.2, 28.1)
w/o ASA	(90.7, 95.8)	(91.9, 48.4)	(85.9, 88.7)	(95.4, 28.5)
w/o $\mathcal{L}_{dis}$	(91.4, 96.1)	(91.5, 48.0)	(86.8, 89.3)	(95.1, 27.7)
DyC-CLIP	**(92.1, 96.6)**	**(92.2, 48.6)**	**(87.2, 89.8)**	**(95.6, 28.6)**

FDA의 효과

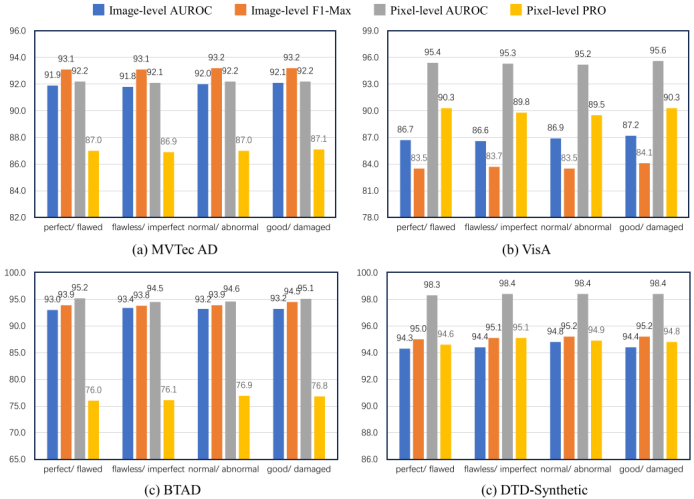
FFT	Feature extraction			MVTec-AD		VisA	
	CNN	ViT	SSM	Image-level	Pixel-level	Image-level	Pixel-level
	✓			(90.8, 95.3)	(91.3, 86.3)	(85.8, 88.7)	(94.5, 89.3)
✓	✓			(91.5, 96.1)	(91.8, 86.7)	(86.4, 89.1)	(95.1, 89.8)
✓		✓		(91.8, 96.2)	(91.8, 86.8)	(86.9, 89.5)	(95.2, 89.7)
✓			✓	**(92.1, 96.6)**	**(92.2, 87.1)**	**(87.2, 89.8)**	**(95.6, 90.3)**

Decoupling loss 가중 계수의 영향

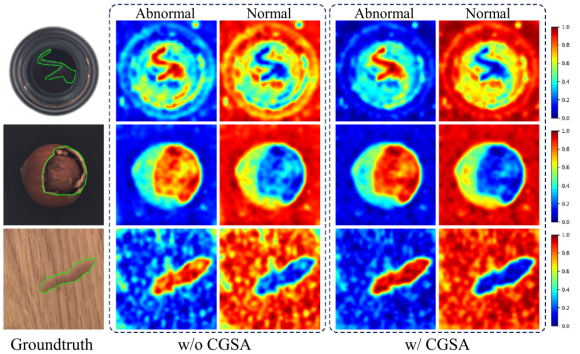
Value setting	MVTec AD		VisA	
	Image-level	Pixel-level	Image-level	Pixel-level
0.1	(91.6, 96.4)	(91.8, 86.7)	(86.9, 89.3)	(95.3, 90.1)
0.2	(91.9, 96.3)	(**92.2**, 86.9)	(87.0, 89.6)	(95.4, 90.2)
0.5	(**92.1**, **96.6**)	(**92.2**, **87.1**)	(**87.2**, **89.8**)	(**95.6**, **90.3**)
1.0	(91.8, 96.3)	(92.1, 86.7)	(86.8, 89.5)	(95.5, **90.3**)
1.5	(91.6, 96.1)	(92.0, 86.8)	(86.5, 89.4)	(95.3, 90.2)

- $\mathcal{L}_{total} = \mathcal{L}_{global} + \mathcal{L}_{local} + \lambda \mathcal{L}_{dis}$

상태 단어의 변형과 강건성



CGSA 모듈의 효과



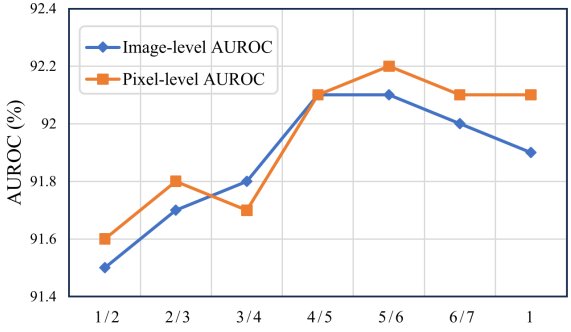
- CGSA를 사용할 경우 더욱 명확하게 윤곽 포착, 노이즈 완화
- 정상/이상 프롬프트에서 정상/이상 영역에 더 강한 반응 보임
- 이미지 텍스트 정렬 및 이상 판별력이 향상

집계 범위의 효과

	MVTec-AD		VisA	
r	AUROC	P-AUROC	AUROC	P-AUROC
$\{1\}$	91.1	91.3	86.8	94.9
$\{1,3\}$	91.6	92.0	**87.3**	95.4
$\{1,3,5\}$	**92.1**	92.2	87.2	**95.6**
$\{1,3,5,7\}$	91.8	92.4	86.9	95.3
$\{1,3,5,7,9\}$	91.3	**92.5**	86.5	95.3

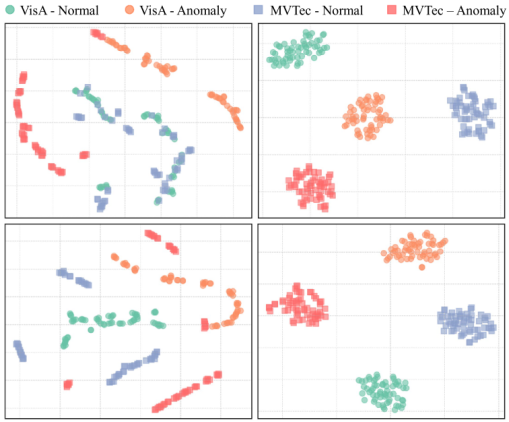
- 데이터의 이상 영역 크기에 따라 최적의 집계 범위 넓이가 달라짐

Top-k의 효과



- k가 너무 작으면 정보 부족으로 성능 저하, 5/6에서 최적 달성
- k를 너무 늘리면 불필요한 정보와 노이즈까지 반영되어 성능 저하

텍스트 공간 시각화



- MVTec-AD: bottle, capsule
- ViaA: candle, cashew
- 텍스트 임베딩 60개 랜덤 추출
- AdaCLIP 보다 더 명확한 분리

사전학습 백본의 영향

Pretrained backbone	AUROC	AP	P-AUROC	P-PRO	Time (ms)
ViT-B-16-224	85.6	93.4	89.7	79.8	**31.9**
ViT-L-14-224	88.9	94.7	91.7	83.6	47.8
ViT-L-14-336	**92.1**	**96.6**	**92.2**	**87.1**	49.3

- 약 4억개의 이미지가 있는 WIT(WebImageText) 데이터셋으로 사전학습
- ViT-규모(base, large)-Patch size-입력크기

결론

- 제로샷 이상 탐지를 위한 CLIP 기반 DyC-CLIP 제안
- FDA를 통해 전역 이미지 정보를 텍스트 프롬프트에 통합하여 이상 인식 능력 향상
- CGSA를 통해 패치 수준 특징과 텍스트 임베딩 간의 세밀한 상호작용 촉진
- ASA를 통해 국소 정보와 전역 문맥 정보를 통합하여 비정상 패턴 구분 능력 향상
- 산업 및 의료 분야의 14개 데이터셋에서 SOTA 성능 달성
- 향후 고도화된 VLM을 통합하여 일반화 성능을 더욱 향상할 예정

감사합니다.