중앙대학교

Causal-Tune: Mining Causal Factors from Vision Foundation Models for Domain Generalized Semantic Segmentation

Yin Zhang, Yongqiang Zhang, Yaoyue Zheng, Bogdan Raducanu, Dan Liu

AAAI 2026

박상춘

응용통계학과 (중앙대학교)

2026년 08월 14일

연구 배경: Domain Generalized Semantic Segmentation

- Semantic segmentation은 pixel마다 semantic class를 예측하는 dense prediction task
- 실제 자율주행 환경에서는 학습 때 보지 못한 domain shift가 자주 발생
  - weather: night, snow, fog, rain
  - camera, city, illumination, texture 변화
- **DGSS**: source domain에서만 학습하고, unseen target domain에서 성능을 유지해야 함

Source Domain

Cityscapes / GTA5

⇓ generalization

Unseen Target Domains

ACDC / BDD100K / Mapillary

Background: Vision Foundation Model (VFM)

- **Vision Foundation Model (VFM)**은 대규모 이미지 데이터로 사전학습된 범용 vision backbone
- DINOv2, CLIP, SAM 같은 모델은 다양한 downstream task에서 재사용 가능한 feature representation을 제공
- Semantic segmentation에서는 VFM encoder가 만든 dense feature를 decoder가 받아 pixel-level prediction을 수행

Pretraining
대규모 데이터로 일반적인 시각 표현 학습

Frozen Encoder
backbone 가중치는 대부분 유지

Dense Prediction
decoder가 segmentation map 예측

이 논문에서는 DINOv2를 frozen VFM backbone으로 사용한다.

Background: Parameter-Efficient Fine-Tuning (PEFT)

- **Parameter-Efficient Fine-Tuning (PEFT)**은 큰 backbone 전체를 업데이트하지 않고, adapter/token/low-rank module 같은 작은 parameter만 학습하는 방식
- VFM의 일반적인 representation은 유지하면서, downstream task에 필요한 보정만 추가하는 것이 목표
- 대표적으로 원본 feature에 작은 update를 residual 형태로 더함

Full fine-tuning
backbone 전체 업데이트
비용과 overfitting 위험 증가

PEFT
backbone은 freeze, 작은 module만 학습
적은 parameter로 domain/task adaptation 수행

$$\hat{f}_i = f_i + \Delta f_i, \qquad \Delta f_i = \mathrm{Adapter}(f_i)$$

기존 VFM-PEFT 방식의 한계

- Rein, SET, FADA 같은 VFM 기반 DGSS 방법은 frozen VFM feature에 adapter/token update를 추가해 unseen domain 성능을 높임
- 일반적인 PEFT update는 입력 feature 전체에서 Δf_i를 생성하므로, useful semantic information과 artifact를 명시적으로 구분하지 않음
- 따라서 adapter가 domain generalization에 도움이 되는 factor뿐 아니라, redundant feature나 domain-specific artifact까지 함께 refine할 수 있음

기존 PEFT 관점

$$\Delta f_i = \mathrm{Adapter}(f_i)$$

feature 전체에서 update 생성

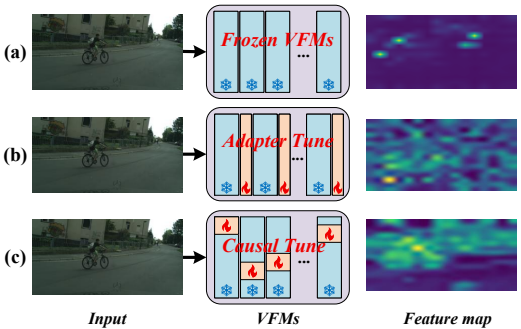
Causal-Tune 관점

$$\Delta f_i = \mathrm{Adapter}(f_i^{cau})$$

causal component를 먼저 선택한 뒤 update 생성

핵심 질문: VFM feature 안의 모든 정보를 똑같이 refine해도 되는가?

문제 제기: VFM Feature Artifacts



- Frozen DINOv2 feature map에는 눈에 띄는 **artifacts**가 존재
- 기존 adapter fine-tuning 후에도 artifacts가 완전히 사라지지 않음
- 논문은 이를 long-term pretraining에서 생긴 redundant feature 또는 non-causal factor와 연결

Causal-Tune의 관점
artifact를 억제하고, generalization에 필요한 causal factor만 refine

Causal Factor와 Non-causal Factor

Causal Factors

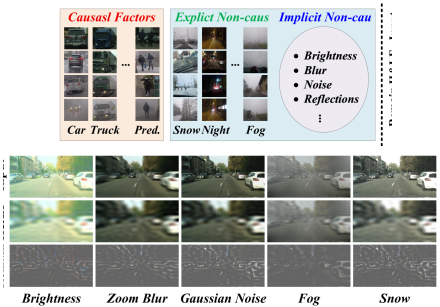
Domain이 바뀌어도 semantic label 예측에 필요한 안정적인 정보

- road / car / building 구조
- object shape, boundary, layout

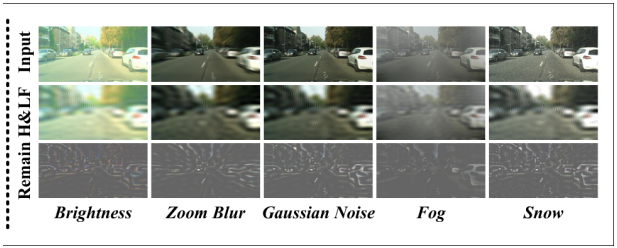
Non-causal Factors

특정 domain에 강하게 나타나는 style, artifact, disturbance

- explicit: rain, snow, fog, night
- implicit: brightness, blur, noise, reflection



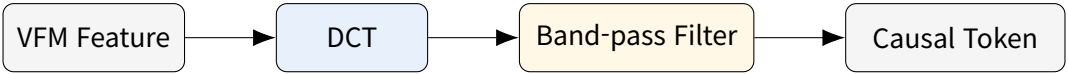
Observation: Non-causal Factor는 어디에 있는가?



- 입력 이미지에 brightness, zoom blur, noise, fog, snow를 인위적으로 적용
- DCT 후 H&LF component와 residual component를 분리해 iDCT로 시각화
- 관찰: H&LF에는 corruption이 강하게 남고, residual에는 structure/texture가 상대적으로 유지

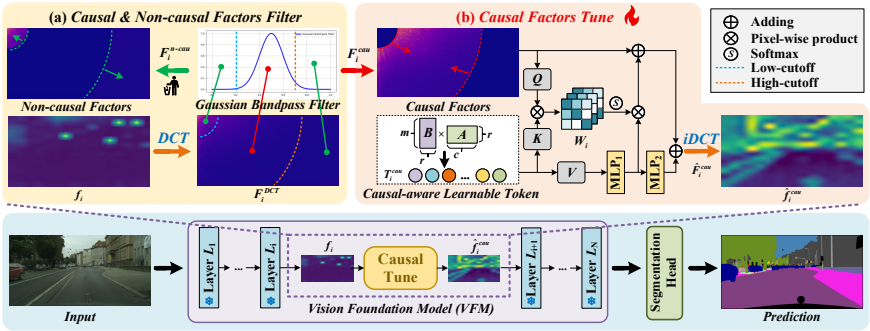
논문의 핵심 아이디어

- Spatial domain에서 causal factor와 non-causal factor를 직접 분리하기는 어려움
- 논문은 VFM feature를 **Discrete Cosine Transform (DCT) spectrum**으로 변환하여 frequency domain에서 분리
- 저자들은 extreme low/high-frequency에 non-causal factor가 상대적으로 많고, middle-frequency에 invariant한 structure/textural pattern이 남는다고 해석



Non-causal component는 adapter branch에서 억제하고, causal component를 refine한다.

Overall Framework



- 각 VFM layer feature에 대해 DCT를 적용하고, causal / non-causal factor를 분리
- Non-causal factor는 refinement branch에서 사용하지 않고, causal factor에서 residual update를 생성

PEFT 삽입 구조: 원본 Feature를 대체하는가?

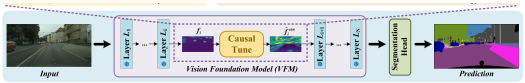
- Frozen VFM layer는 그대로 유지하고, Causal-Tune은 각 layer 사이에 작은 update branch로 삽입됨
- 기존 PEFT는 feature 전체에서 update Δf_i를 만들 수 있음
- Causal-Tune은 DCT spectrum에서 causal component만 이용해 Δf_i를 생성

General PEFT

$$\hat{f}_{i+1} = L_{i+1}(f_i + \Delta f_i)$$

Causal-Tune

$$\Delta f_i = \mathrm{CausalTune}(f_i)$$



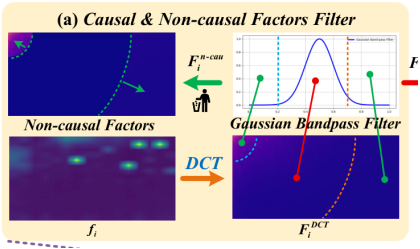
중요: Non-causal factor를 전체 network에서 완전히 삭제하는 것이 아니라, adapter가 만드는 refinement에서 제외하는 것으로 이해하는 것이 안전하다.

Step 1. VFM Feature를 DCT Spectrum으로 변환

- i번째 VFM layer의 spatial feature를 $f_i(h, w)$로 둠
- **Discrete Cosine Transform (DCT)**를 통해 frequency-domain feature $F_i^{DCT}(u, v)$로 변환
- DCT spectrum에서는 spatial pattern이 cosine basis의 조합으로 표현됨

$$f_i(h, w) \xrightarrow{\text{DCT}} F_i^{DCT}(u, v)$$

spatial feature를 cosine basis의 coefficient로 변환



Frequency intuition
low: global brightness / smooth variation
middle: object structure / texture
high: noise / sharp artifacts / fine details

DCT는 어느 축에 적용되는가?

- 논문 수식에서 DCT 좌표는 $(h, w) \rightarrow (u, v)$
- 따라서 feature channel마다 spatial map $H \times W$에 2D DCT를 적용하는 것으로 이해할 수 있음
- Channel dimension c는 semantic feature dimension으로 유지됨

$$f_i \in \mathbb{R}^{H \times W \times c}$$

$$f_i(h, w, :) \xrightarrow{\text{2D DCT}} F_i^{DCT}(u, v, :)$$

$$F_i^{DCT} \in \mathbb{R}^{H \times W \times c}$$

해석: frequency 위치 (u, v)마다 c-dimensional VFM feature vector가 존재한다.

Step 2. Gaussian Band-pass Filter

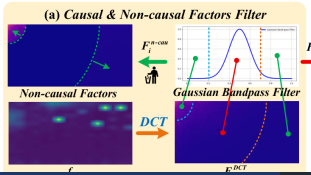
- Low/high cutoff를 가진 Gaussian band-pass filter 사용
- 너무 낮은 frequency와 너무 높은 frequency는 non-causal factor로 간주
- 가운데 frequency를 상대적으로 통과시키는 **soft weighting mask**

$$G(u,v) = \exp\left(-\frac{u^2+v^2}{2R_H^2}\right) - \exp\left(-\frac{u^2+v^2}{2R_L^2}\right)$$

$$F_i^{cau} = F_i^{DCT}(u,v) \cdot G(u,v)$$

$$F_i^{n-cau} = F_i^{DCT}(u,v) \cdot (1 - G(u,v))$$

Default: $R_L = 0.2,\ R_H = 0.7$



왜 Low와 High를 Non-causal로 보는가?

Extreme low-frequency

- global brightness / contrast
- haze, fog 같은 전체적 smooth shift
- night처럼 scene 전체 illumination 변화

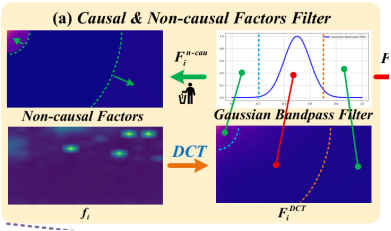
Extreme high-frequency

- noise, reflection, sharp artifact
- snow particle / rain streak
- fine texture에 섞인 domain-specific disturbance

논문의 가정: extreme low/high에는 domain-specific factor가 상대적으로 많고, middle-frequency에는 segmentation에 필요한 structure와 texture가 더 안정적으로 남는다.

Step 3. Causal Component만 Refinement에 사용

- Band-pass filter 후 spectrum은 causal / non-causal 성분으로 나뉨
- F_i^{cau}: segmentation에 필요한 domain-invariant 정보 후보
- F_i^{n-cau}: domain-specific disturbance와 artifact 후보
- F_i^{n-cau}는 **refinement branch**에서 사용하지 않음
- Gaussian mask 관점에서는 hard discard보다 soft attenuation에 가까움

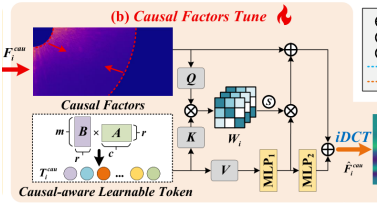


$$F_i^{DCT}$$

Non-causal	Causal	Non-causal
low	middle	high
suppress	tune	suppress

Step 4. Causal-aware Learnable Token

- 각 VFM layer마다 causal factor를 refine하기 위한 learnable token T_i^{cau}를 둠
- Token은 low-rank factorization으로 parameter 수를 줄임
- 역할: frequency domain의 causal factor에서 task-specific knowledge를 끌어와 segmentation에 맞게 보정



$$T_i^{cau} = B_i A_i, \quad T_i^{cau} \in \mathbb{R}^{m \times c}$$

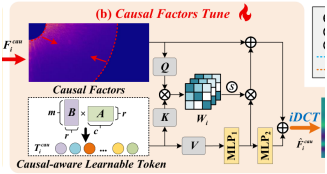
$$B_i \in \mathbb{R}^{m \times r}, \quad A_i \in \mathbb{R}^{r \times c}$$

왜 low-rank? VFM은 freeze하고 작은 token parameter만 학습하기 위해서

Step 5. Attention-like Causal Factor Refinement

- Flatten하면 causal component는 $F_i^{cau} \in \mathbb{R}^{HW \times c}$로 볼 수 있음
- Learnable token은 $T_i^{cau} \in \mathbb{R}^{m \times c}$
- Similarity map은 각 frequency 위치와 token 사이의 관련도

$$W_i \in \mathbb{R}^{HW \times m}$$



$$W_i = \text{Softmax}\left(\frac{F_i^{cau} T_i^{cau\top}}{\sqrt{c}}\right)$$

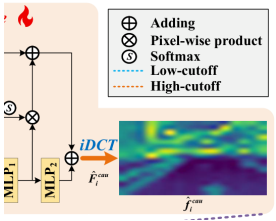
$$\tilde{F}_i^{cau} \leftarrow F_i^{cau} + W_i \, MLP_1(T_i^{cau})$$

$$\hat{F}_i^{cau} = F_i^{cau} + MLP_2(\tilde{F}_i^{cau})$$

pixel-wise product라는 설명과 matrix multiplication 형태의 수식 사이에 다소 모호함이 있다.

Step 6. iDCT로 Spatial Feature 복원

- Token으로 refined된 causal factor는 아직 frequency domain에 있음
- 다음 VFM layer 또는 segmentation head로 전달하려면 spatial feature로 복원해야 함
- iDCT를 적용해 spatial-domain update Δf_i를 얻고, 원본 feature에 residual로 더함



$$f_i(h,w) \xrightarrow{DCT} F_i^{DCT}$$

$$F_i^{cau} \xrightarrow{Token} \hat{F}_i^{cau}$$

$$\hat{F}_i^{cau} \xrightarrow{iDCT} \Delta f_i$$

Experimental Setup

- **Task**: Domain Generalized Semantic Segmentation
- **Backbone**: DINOv2
- **Segmentation head**: Mask2Former
- **Optimizer**: AdamW, lr 1×10^{-4}
- **Training**: 40K iterations, batch size 4
- **Input**: 512 $\times$ 512
- **Metric**: mIoU, 3 independent runs 평균

Datasets

- Cityscapes / GTA5
- ACDC: night / snow / fog / rain
- BDD100K / Mapillary

Evaluation settings

- Cityscapes $\rightarrow$ ACDC / BDD / Mapillary
- GTA5 $\rightarrow$ Cityscapes / BDD / Mapillary

Main Result: Cityscapes → ACDC

Method	Night	Snow	Fog	Rain	Avg.
Rein	55.9	70.6	79.5	72.5	69.6
SET	57.3	73.6	80.1	74.8	71.5
FADA	**57.4**	73.5	80.2	75.0	71.5
Causal-Tune	56.2	**75.4**	**81.3**	**75.2**	**72.0**
vs Rein	+0.3	+4.8	+1.8	+2.7	+2.4

- ACDC 평균 mIoU에서 Rein 대비 +2.4 향상
- Snow, Fog, Rain에서 가장 강한 개선
- Night에서는 +0.3으로 개선 폭이 작음

Cross-Domain Generalization Results

Method	$C \to B$	$C \to M$	$G \to C$	$G \to B$	$G \to M$
Rein	63.54	74.03	66.40	60.40	66.10
SET	65.07	75.67	68.06	61.64	67.68
FADA	65.12	75.86	**68.23**	**61.94**	68.09
Causal-Tune	**66.28**	**76.05**	66.22	61.80	**68.21**

- Real-to-real setting인 $C \to B$, $C \to M$에서 SOTA 성능
- Synthetic-to-real 중 $G \to M$은 최고 성능, $G \to C$는 약점
- 저자들은 synthetic-to-real에서는 causal factor mining이 어려울 수 있다고 해석

Ablation 1: FFT / HWT / DCT 비교

Transform	Night	Snow	Fog	Rain	Avg.
FFT	**57.1**	71.1	80.6	69.2	69.5
HWT	52.8	72.2	79.4	72.4	69.2
DCT	56.2	**75.4**	**81.3**	**75.2**	**72.0**

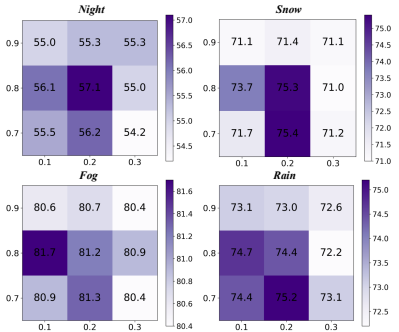
- FFT(Fast Fourier Transform)는 Night 조건에는 강하지만, 전체 평균은 낮음
- HWT(Haar Wavelet Transform; Haar wavelet 기반 multi-resolution 변환)는 causal/non-causal factor를 잘 분리하지 못하는 것으로 해석
- DCT(Discrete Cosine Transform)가 adverse weather 평균에서 가장 좋은 결과
- Table 2의 나머지 cross-domain setup에서도 DCT가 FFT/HWT보다 전반적으로 높은 성능

Ablation 2: Low / High / Band-pass Filtering

Filter	Night	Snow	Fog	Rain	Avg.
None	55.9	70.6	79.5	72.5	69.6
LF 제거	**57.3**	72.1	73.2	71.1	68.4
HF 제거	54.8	73.7	80.5	74.1	70.4
LF+HF 제거	56.2	**75.4**	**81.3**	**75.2**	**72.0**

- Night에서는 low-frequency 제거가 가장 큰 효과
- Snow/Fog/Rain은 high-frequency 또는 band-pass가 효과적
- Condition마다 non-causal factor가 위치한 frequency가 다를 수 있음

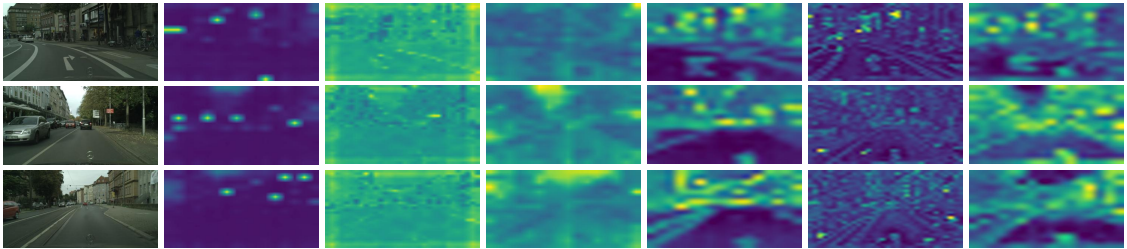
Cutoff Frequency Analysis



- R_L, R_H 조합을 바꾸며 $C \rightarrow$ ACDC 성능을 측정
- Default: $R_L = 0.2$, $R_H = 0.7$
- 너무 강한 filtering은 useful causal 정보까지 억제할 수 있음
- frequency coordinate normalization과 cutoff 구현 세부는 논문에 명확히 보고되지 않음

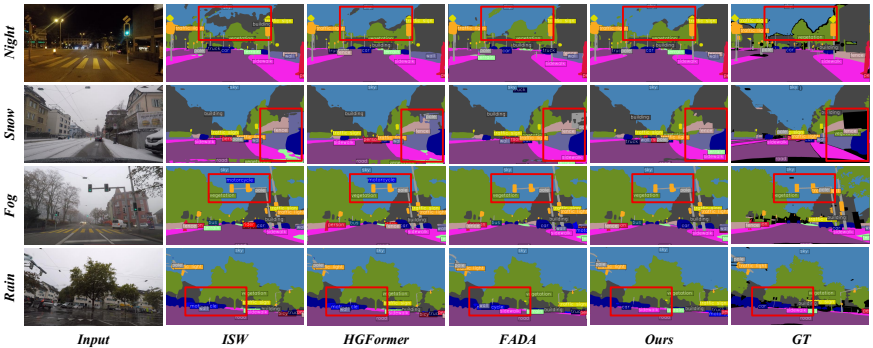
Limitation: 고정 cutoff라 condition, image, layer에 따라 최적값이 달라질 수 있음

Feature Map Visualization



- Frozen DINOv2, EVA02, CLIP feature map에서 artifacts가 관찰됨
- 저자들은 Causal-Tune 적용 후 artifacts가 줄고, scene structure에 더 집중한다고 해석

Segmentation Visualization



- Night, Snow, Fog, Rain 조건에서 기존 방법들과 비교
- 저자들은 boundary와 region prediction이 더 안정적이라고 해석

논문의 강점과 한계

Strengths

- VFM artifact 문제를 causal 관점으로 해석
- DCT + band-pass filter라는 단순한 구조
- adverse weather DGSS에서 효과적
- Frozen VFM + low-rank token 기반 PEFT 형태

Limitations

- causal은 엄밀한 인과 식별보다 operational definition에 가까움
- cutoff가 고정되고 좌표 정규화 세부가 불명확
- Night 개선 폭이 작고 synthetic-to-real setting에서 약점
- 표준편차, parameter, FLOPs, latency를 보고하지 않음

Conclusion

- Causal-Tune은 VFM feature 안의 causal / non-causal factor를 frequency domain에서 분리하려는 DGSS 방법
- DCT spectrum에 Gaussian band-pass filter를 적용해 middle-frequency causal factor를 유지
- Non-causal component는 refinement branch에서 억제하고, causal-aware token으로 causal component를 refine
- Adverse weather DGSS에서 Rein 대비 평균 +2.4 mIoU, Snow에서 +4.8 mIoU 향상

Takeaway

VFM fine-tuning에서는 무엇을 학습할 것인가만큼
무엇을 억제하고 어디를 보완할 것인가도 중요하다.

감사합니다.